

情報工学実験 II レポート

自然言語処理

人間情報システム工学科 4 年 45 番

山口惺司

実験日：	2024 年 12 月 11 日
	2024 年 12 月 4 日
締切：	2024 年 12 月 18 日
提出日：	2024 年 12 月 18 日

評価項目	やった/一部やった/やっていない/何をやったかの概要
形態素解析の対象とした文書	斜陽 / 太宰治
正規表現の説明を行った	何を加えたか：英数字，記号，空白，改行，句読点，読点，括弧，の削除
追加的課題：	やってない
追加的課題：	やってない

背景と実験目的

背景：

自然言語処理が含む内容は極めて多岐にわたるが、今回の学生実験のテーマでは、Gensim というライブラリ群に入っている Word2Vec という比較的有名なツールを用いて、自然言語処理の一部を体験してみる。形態素解析、正規表現、分散表現(単語のベクトル化)などのいくつかの技術や概念に触れ、基礎的な知識を得る。

目的：

- ・ 正規表現の基礎的な機能を使うことができる
- ・ ストップワードの基礎的な機能を説明できる
- ・ 形態素解析の基礎的な機能を使うことができる

課題 1

【問題】

- 何らかのテキストに対して、形態素解析ツールを用い、分かち書きし、ファイルに出力する
- プログラム中の正規表現を用いて部分について、どのような処理を行っているか、説明を数行書く

【アルゴリズム・解き方】

今回は太宰治の「斜陽」を用いて、データの解析を行う。

1. 解析するテキストデータを用意する。
2. 正規表現を使って単語以外の文字をテキストデータから削除する。
3. Janome を用いて分かち書きをし、ファイルに出力する。

正規表現では以下のような文字をテキストデータから削除している。

「英数字、記号、空白の行、空白、括弧、句読点、読点」

【実行結果】

実行結果は出力されたファイルの冒頭 10 単語の句読点なしを図 1、句読点ありを図 2 に示す。

⇒ ['朝食', '堂', 'で', 'スープ', 'を', '一', 'さじ', 'すっと', '吸っ', 'て']

図 1 出力されたファイルの冒頭 10 単語

⇒ ['朝', '、', '、', '食堂', 'で', 'スープ', 'を', '一', 'さじ', '、', '、', 'すっと']

図 2 出力されたファイルの冒頭 10 単語(句読点あり)

【考察】

図 1 を見ると前処理で「、」をデータから削除しているため本来「朝、食堂でスープを一さじ、....」という文が「朝食」と「堂」で分かれてしまい、意味が変わってしまっていることがわかる。

そこで、データから句読点を削除しなかった場合の実行結果である図 2 を見ると正しい単語の塊で出力されていることがわかる。

まとめ

前処理の仕方次第で単語の処理が変わってしまうため、工夫が必要だということがわかった。

参考文献

青空文庫：太宰治 斜陽

https://www.aozora.gr.jp/cards/000035/files/1565_8559.html

付録

【プログラムソース】

```
from janome.tokenizer import Tokenizer
import re

def preprocessing(text):
    text = re.sub("[a-zA-Z0-9_]", "", text)
    text = re.sub("[!-/:-@[-`{-~*]", "", text)
    text = re.sub(u'¥n¥n', '¥n', text)
```

```

text = re.sub(u'¥r', '', text)
text = re.sub(r'《.*?》', '', text)
text = re.sub(r'[.*?]', '', text)
text = re.sub(r"[\ ]? !。 ]", "", text)
return text

def save_wakati_file(wakati_list, save_path='wakati.txt'):
    with open('./' + save_path, mode="w", encoding='utf-8') as
f2:
        f2.write(' '.join(wakati_list))

def main():
    tokenizer = Tokenizer()

    f1 = open('shayo.txt', 'r', encoding='UTF-8')
    s = f1.read()
    f1.close

    text = preprocessing(s)

    tokens = tokenizer.tokenize(text, wakati=True)
    w = list(tokens)

    save_wakati_file(w)

    print(w[1 : 11])

if __name__ == "__main__":
    main()

```